

NB : cette fiche présente les techniques nécessaires **minimales** des séries statistiques bivariées ; elle ne constitue donc pas un objectif mais un pré-requis pour le traitement des séries statistiques !

1 Série statistique bivariée

Soit (X, Y) une série statistique quantitative observée sur une même population de taille n .

— Le point moyen ou le centre de gravité de la série (X, Y) est défini pour

a) les données simples par : $\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$, $\bar{Y} = \frac{1}{n} \sum_{i=1}^n y_i$.

b) les données groupées par : $\bar{X} = \frac{1}{n} \sum_{i=1}^p n_i x_i$, $\bar{Y} = \frac{1}{n} \sum_{i=1}^p n_i y_i$ où $n = \sum_{i=1}^p n_i$.

— La variance de Z (où Z joue le rôle de X ou de Y) est définie pour

a) les données simples par : $V(Z) = \overline{Z^2} - (\bar{Z})^2 = \frac{1}{n} \sum_{i=1}^n z_i^2 - \left(\frac{1}{n} \sum_{i=1}^n z_i \right)^2$.

b) les données groupées par : $V(Z) = \overline{Z^2} - (\bar{Z})^2 = \frac{1}{n} \sum_{i=1}^p n_i z_i^2 - \left(\frac{1}{n} \sum_{i=1}^p n_i z_i \right)^2$ où $n = \sum_{i=1}^p n_i$.

— La covariance de la série (X, Y) est définie pour

a) les données simples par : $Cov(X, Y) = \overline{XY} - \bar{X} \times \bar{Y} = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{X} \times \bar{Y}$.

b) les données groupées par : $Cov(X, Y) = \frac{1}{n} \sum_{i=1}^p n_i x_i y_i - \bar{X} \times \bar{Y}$ où $n = \sum_{i=1}^p n_i$.

2 Tableau de contingence

2.1 Distribution en effectif et en fréquence

— La distribution en effectif ou **en fréquence** de la série (X, Y) est donnée par le tableau suivant :

$X \backslash Y$	y_1	\cdots	y_j	\cdots	y_m	Σ
x_1	n_{11} ou f_{11}	\cdots	n_{1j} ou f_{1j}	\cdots	n_{1m} ou f_{1m}	$n_{1\cdot}$ ou $f_{1\cdot}$
\vdots	\vdots	\ddots	\vdots	\ddots	\vdots	\vdots
x_i	\vdots	\ddots	n_{ij} ou f_{ij}	\ddots	\vdots	$n_{i\cdot}$ ou $f_{i\cdot}$
\vdots	\vdots	\ddots	\vdots	\ddots	\vdots	\vdots
x_k	n_{k1} ou f_{k1}	\cdots	n_{kj} ou f_{kj}	\cdots	n_{km} ou f_{km}	$n_{k\cdot}$ ou $f_{k\cdot}$
Σ	$n_{\cdot 1}$ ou $f_{\cdot 1}$	\cdots	$n_{\cdot j}$ ou $f_{\cdot j}$	\cdots	$n_{\cdot m}$ ou $f_{\cdot m}$	$n = \sum_{i=1}^k n_{i\cdot} = \sum_{j=1}^m n_{\cdot j}$ ou 1

où

— n_{ij} est le nombre de fois où la modalité x_i de X et la modalité y_j de Y ont été observées simultanément.

— $n_{i\cdot} = \sum_{j=1}^m n_{ij}$ est l'effectif marginal de la modalité x_i de X .

— $n_{\cdot j} = \sum_{i=1}^k n_{ij}$ est l'effectif marginal de la modalité y_j de Y .

— $f_{ij} = \frac{n_{ij}}{n}$ est la proportion $\frac{n_{ij}}{n}$ ou le pourcentage $\frac{n_{ij}}{n} \times 100\%$ des individus possédant à la fois la modalité x_i de X et la modalité y_j de Y .

— $f_{i\cdot} = \frac{n_{i\cdot}}{n}$ est la fréquence marginale de la modalité x_i de X indépendamment de Y .

— $f_{\cdot j} = \frac{n_{\cdot j}}{n}$ est la fréquence marginale de la modalité y_j de Y indépendamment de X .

2.2 Distribution marginale en effectif ou en fréquence

— La distribution marginale de X en effectif ou **en fréquence** est :

X	Effectif marginal
x_1	$n_{1.}$
\vdots	\vdots
x_i	$n_{i.}$
\vdots	\vdots
x_k	$n_{k.}$
Σ	$n = \sum_{i=1}^k n_{i.}$

X	fréquence marginale
x_1	$f_{1.}$
\vdots	\vdots
x_i	$f_{i.}$
\vdots	\vdots
x_k	$f_{k.}$
Σ	1

— La distribution marginale de Y en effectif ou **en fréquence** est :

Y	Effectif marginal
y_1	$n_{.1}$
\vdots	\vdots
y_j	$n_{.j}$
\vdots	\vdots
y_m	$n_{.m}$
Σ	$n = \sum_{j=1}^m n_{.j}$

Y	fréquence marginale
y_1	$f_{.1}$
\vdots	\vdots
y_j	$f_{.j}$
\vdots	\vdots
y_m	$f_{.m}$
Σ	1

2.3 Moyenne marginale et variance marginale

— La moyenne marginale de X (respectivement de Y) est définie par :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^k n_{i.} x_i \quad \left(\text{resp. } \bar{Y} = \frac{1}{n} \sum_{j=1}^m n_{.j} y_j \right)$$

— La variance marginale de X (respectivement de Y) est définie par :

$$S_X^2 = \frac{1}{n} \sum_{i=1}^k n_{i.} (x_i - \bar{X})^2 \quad \left(\text{resp. } S_Y^2 = \frac{1}{n} \sum_{j=1}^m n_{.j} (y_j - \bar{Y})^2 \right)$$

2.4 Dépendance entre deux variables X et Y

On considère la fréquence marginale $f_{i.}$ du i^{eme} individus de la variable X et la fréquence marginale $f_{.j}$ du j^{eme} individus de la variable Y . Pour $1 \leq i, j \leq n$, on note f_{ij} la fréquence du couple (x_i, y_j) .

— Les variables X et Y sont **indépendantes** si pour tout $1 \leq i, j \leq n$, on a $f_{ij} = f_{i.} \times f_{.j}$.

— Les variables X et Y sont **dépendantes** s'il existe un $(i, j) \in \{1, \dots, n\}$ telle que $f_{ij} \neq f_{i.} \times f_{.j}$.

3 Ajustement linéaire par la méthode des moindres carrés

— Le coefficient de corrélation linéaire est $r(X, Y) = \frac{Cov(X, Y)}{V(X)}$.

— La droite de régression ou des moindres carrés de Y en fonction de X est $y = ax + b$ où $a = \frac{Cov(X, Y)}{V(X)}$ et $b = \bar{Y} - a\bar{X}$.